

FLAFA • FAMILY FLIGHT-GIMBAL AGENT

Evaluation Framework | 评测方法与已验证成果

FLAFA v8.4.0 | Evaluation Summary | 评测摘要 | 2026-08-18

对外技术资料

FLAFA v8.4.0

FLAFA v8.4.0 | Evaluation Summary | 评测摘要 | 2026-08-18

FLAFA 的评测不只判断回答“看起来是否合理”，而是同时检查结构合同、候选引用、关键语义、禁用字
段、系统安全、运行状态和真实模型表现。

1. 分层评测

评测层	主要对象	验证重点
Deterministic Regression 确定性回归	合同、状态、幂等、安全和 Visual 协议	规则行为可重复、可回归
Real Planner Evaluation 真实规划模型	qwen3.7-max 与 P01-P17	意图、澄清、边界、结构和安全语义
System Safety Evaluation 系统安全	S01-S03	低电量、路径阻断、回退与安全链
Visual Model Evaluation 视觉模型	Wan 方案预览与拍摄表达	人物、空间、活动、媒介和安全表达
ASR Evaluation 语音识别	Web Speech 与页面流程	权限、连续识别、确认、错误和键盘回退
Full Rehearsal 完整彩排	启动、主链路、追问、Visual、Runtime 和停止	锁定环境下的可复现性

2. 判定原则

- Critical Check 失败即案例失败，不能用总分掩盖。
- live 模式失败不能用确定性回退覆盖。
- 超时、上游错误、合同错误和语义错误分别记录。
- 视觉模型同时进行自动检查和人工复核。
- 修复后运行相关专项与全量回归，防止局部修复造成其他链路退化。

3. 锁定成果

证据	锁定结果	结论边界
Frontend 前端	11 个测试文件、101 项测试通过，生产构建通过	不承诺浏览器语音上游始终低延迟
Backend 本地服务	102 项回归测试通过	验证软件合同和确定性行为
Real Planner 真实规划模型	P01-P17 最终全量通过	适用于锁定测试集，不代表覆盖所有自然语言
System Safety 系统安全	S01 5/5、S02 4/4、S03 5/5	不替代真实飞行安全认证
Visual 视觉模型	Wan 真实调用、合同、人工复核、缓存与回退专项完成	预览不承诺与真实相机像素一致
ASR and Rehearsal 语音与彩排	权限、转写、确认、追问补充、键盘回退和完整流程通过	Web Speech 仍受浏览器与网络影响

4. 评测价值

这套框架把生成式模型评测与系统工程验证结合起来：模型负责语义能力，合同和规则负责可预测性，安全专项负责阻断风险，完整彩排负责证明端到端链路能够在锁定环境中复现。